Appendix A

Python code for bias analysis

```
import torch
import torchtext
import numpy as np
import spacy
from pyfasttext import FastText
# Load spaCy model and FastText model
nlp = spacy.load("en_core_web_lg")
model = FastText()
model.load_model("/content/sample_data/cc.de.300.bin")
glove = torchtext.vocab.GloVe(name="6B", dim=50)
# GloVe bias analysis
def glove_bias_values(definite_sets, analogy_templates,
test_terms):
results = []
input_words = [item for sublist in definite_sets for item in
sublist]
for tword in test_terms:
for iword in input_words:
x = glove.vectors[glove.stoi[iword]]
y = glove.vectors[glove.stoi[tword]]
result = {}
result["input"] = iword
result["target"] = tword
result["distance"] = torch.norm(y - x).item()
result["cosine"] = cos_sim(x, y)
results.append(result)
return results
results_glove = glove_bias_values(definite_sets, analogy_templates,
output_glove = """# Glove output for Gender bias:
| input | manager | executive | doctor | lawyer | programmer | scientist | soldier |
supervisor | rancher| janitor| firefighter | officer|
# Create a dictionary to store cosine similarity values for each target
target_columns = {target: [] for target in test_terms}
for result in results_glove:
input_word = result['input']
for target in test_terms:
  if target == result['target']:
    target_columns[target].append(round(result['cosine'],
5))
# Populate the output_glove with the values from the dictionary
for input_word in definite_sets[0]:
  row = f"{input_word}"
  for target in test_terms:
      row += f"{target_columns[target].pop(0)}|"
```

```
output_glove += row + "\n"
# Display the table
display (Markdown(output_glove))
```

Table A1: Words like "Islam" and "jihad" are regularly associated with the phrase's "terrorist" and "terrorism" by the word embeddings (Glove, SpaCy, FastText).

terrorism Bias	input	islam	hinduism	hindutva	buddhism	christianity	hindu	wahabi	jihad	men	women	man	woman
Glove Output	terrorist	0.528	0.098	0.098	0.145	0.296	0.293	0.058	0.674	0.451	0.343	0.457	0.314
Giove Output	terrorism	0.623	0.165	0.152	0.275	0.400	0.255	0.058	0.574	0.439	0.429	0.457 0.415 0.163 0.056 0.300 0.212	0.304
Fasttext Output	terrorist	0.420	0.183	0.168	0.272	0.345	0.328	0.285	0.443	0.259	0.314	0.163	0.372
rastiext Output	terrorism	0.413	0.262	0.247	0.376	0.492	0.279	0.261	0.551	0.279	0.409	0.457 0.415 0.163 0.056 0.300	0.331
	terrorist	0.304	0.068	0.000	0.160	0.309	0.123	0.000	0.583	0.232	0.234	0.300	0.263
SpaCy Output	terrorism	0.308	0.179	0.000	0.244	0.387	0.154	0.000	0.591	0.208	0.297	0.457 0.415 0.163 0.056 0.300	0.209

Table A2: Gender bias throughout the various word embeddings (Glove, SpaCy, FastText). Words like "she" and "woman" have highest similarities with the terms like "nurse," "maid," and "hairdresser," and lowest similarities with the terms like "firefighter" and "officer."

Gender bias	input	secretary	nurse	clerk	artist	homemaker	dancer	singer	librarian	maid	hair dresser	stylist	Receptionist	Counsellor
	woman	0.255	0.715	0.470	0.522	0.573	0.586	0.569	0.391	0.645	0.508	0.403	0.446	0.439
er	man	0.346	0.572	0.400	0.507	0.397	0.529	0.513	0.300	0.537	0.391	0.311	0.310	0.350
Glove Output	she	0.399	0.646	0.476	0.546	0.394	0.546	0.538	0.426	0.491	0.357	0.366	0.353	0.442
	he	0.517	0.481	0.476	0.448	0.224	0.390	0.399	0.386	0.304	0.191	0.159	0.310 0.353 0.184 0.272 0.318 0.326 0.216 0.197 0.302 0.354	0.389
	he	0.242	0.307	0.230	0.168	0.221	0.212	0.166	0.160	0.235	0.221	0.076	0.272	0.228
	she	0.194	0.475	0.147	0.224	0.354	0.373	0.276	0.183	0.390	0.377	0.209	0.318	0.247
SpaCy Output	woman	0.178	0.475	0.228	0.302	0.413	0.414	0.307	0.211	0.531	0.380	0.225	0.326	0.262
	man	0.103	0.282	0.218	0.218	0.272	0.286	0.199	0.098	0.408	0.246	0.101	0.216	0.172
	he	0.082	0.209	0.170	0.206	0.005	0.206	0.182	0.172	0.318	0.209	0.084	0.197	0.122
Fasttext output	she	0.250	0.337	0.205	0.269	0.176	0.314	0.285	0.220	0.405	0.330	0.301	0.302	0.303
rastiext output	woman	0.431	0.469	0.389	0.445	0.255	0.503	0.464	0.363	0.465	0.434	0.429	0.354	0.448
	man	0.028	0.014	0.064	0.029	0.204	0.023	0.134	0.060	0.008	0.099	0.095	0.154	0.031

Table A3: Gender bias throughout the various word embeddings (Glove, SpaCy, FastText). It states that certain professions are connected to specific genders. We observed that the words like "man", and "he" refers to the highest similarities with the terms like "manager," "soldier," and "supervisor," and lowest similarities with the terms like "hairdresser" and "stylist."

Gender Bias	input	manager	executive	doctor	lawyer	programmer	scientist	soldier	supervisor	rancher	janitor	firefighter	officer
	he	0.603	0.490	0.691	0.599	0.253	0.448	0.527	0.386	0.138	0.258	0.239	0.617
GI O	she	0.441	0.394	0.728	0.552	0.229	0.416	0.531	0.434	0.127	0.276	0.263	0.521
Glove Output	man	0.444	0.348	0.712	0.607	0.266	0.492	0.732	0.267	0.378	0.355	0.435	0.583
	woman	0.223	0.223	0.725	0.580	0.219	0.439	0.718	0.341	0.367	0.380	0.458	0.484
	he	0.197	0.054	0.415	0.336	0.098	0.251	0.413	0.161	0.290	0.154	0.305	0.301
San Co. Outant	she	0.101	0.023	0.453	0.282	0.077	0.214	0.284	0.156	0.189	0.136	0.286	0.215
SpaCy Output	woman	0.083	0.045	0.456	0.362	0.029	0.274	0.470	0.129	0.298	0.212	0.347	0.325
	man	0.098	-0.028	0.374	0.337	0.029	0.251	0.584	0.072	0.362	0.237	0.239 0.263 0.435 0.458 0.305 0.286 0.347 0.388 0.069 0.107 0.243	0.339
	he	0.127	0.102	0.246	0.265	0.185	0.225	0.230	0.075	0.064	0.098	0.069	0.169
F O	she	0.187	0.184	0.267	0.241	0.258	0.251	0.328	0.204	0.216	0.190	0.107	0.239
Fasttext Output	woman	0.325	0.320	0.369	0.392	0.292	0.485	0.444	0.302	0.236	0.255	0.243	0.446
	man	0.171	0.024	0.148	0.043	0.214	0.077	0.113	0.152	0.277	0.121	0.119	0.127

Table A4: Calculation of associations between Religion and Target words using word embeddings (Glove, SpaCy, Fasttext).

Religion Bias	input	liberal	violent	un educated	dirty	judgemental	terrorism	terrorist	conservative	violent
-	judaism	0.445	0.224	0.145	-0.100	-0.027	0.246	0.180	0.451	0.224
	christianity	0.372	0.340	0.179	-0.086	-0.099	0 0.400 0.296 0.433 0.34 2 0.329 0.297 0.627 0.32 3 0.152 0.098 0.294 0.21 4 0.623 0.528 0.482 0.47 0.422 0.279 0.440 0.30 8 0.563 0.553 0.554 0.59 6 0.165 0.098 0.249 0.24 0.217 0.149 0.342 0.15 0.387 0.399 0.513 0.34 0.251 0.254 0.461 0.22 0.000 0.000 0.000 0.000 0.308 0.304 0.187 0.20 0.307 0.137 -0.032 0.03 0.339 0.369 0.294 0.29 0.179 0.068 0.171 0.141 0.403 0.240 0.326 0.24 0.492 0.345 0.434 0.33 0.260 0.242 0.171 0.19 0.247 0.168 0.173 0.16 0.413 0.420 0.235 0.23 0.036 0.095 0.023 0.03 0.464 0.577 0.302 0.37	0.340		
	christian	0.579	0.329	0.125	0.013	-0.302	0.329	0.297	0.627	0.329
	hindutva	0.295	0.216	0.219	0.174	0.136	0.152	0.098	0.294	0.216
Glove Output	islam	0.394	0.470	0.189	0.165	-0.127	0.623	0.528	0.482	0.470
	jew	0.458	0.303	0.406	0.208	0.017	0.242	0.279	0.440	0.303
	muslim	0.453	0.592	0.275	0.167	-0.198	0.563	0.553	0.540	0.592
	hinduism	0.231	0.248	0.235	-0.124	-0.025	0.165	0.098	0.249	0.248
	judaism	0.399	0.155	0.197	0.025	0.287	0.217	0.149	0.342	0.155
	christianity	0.562	0.345	0.404	0.026	0.442	0.387	0.309	0.513	0.345
	christian	0.487	0.222	0.406	-0.007	0.334	0.251	0.254	0.461	0.222
SpaCy Output	hindutva	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000
Spacy Output	islam	0.287	0.202	0.121	0.093	0.087	0.308	0.304	0.187	0.202
	jew	0.091	0.036	0.162	0.244	-0.087	0.037	0.137	-0.032	0.036
	muslim	0.357	0.297	0.305	0.180	0.107	0.339	0.369	0.294	0.297
	hinduism	0.230	0.140	0.141	0.121	0.234	0.179	0.068	0.171	0.140
	judaism	0.231	0.244	0.247	0.144	0.282	0.403	0.240	0.326	0.244
	christianity 0.372 0.340 0.179 -C christian 0.579 0.329 0.125 0.0 hindutva 0.295 0.216 0.219 0.0 islam 0.394 0.470 0.189 0.0 jew 0.483 0.303 0.406 0. muslim 0.453 0.592 0.275 0. hinduism 0.399 0.155 0.197 0. christiani 0.487 0.222 0.406 0. christian 0.487 0.222 0.406 0. christian 0.287 0.202 0.121 0. jew 0.091 0.036 0.162 0. muslim 0.357 0.297 0.305 0. inidutsva 0.023 0.140 0. 0. jew 0.091 0.036 0.162 0. 0. muslim 0.237 0.244 0.247 0. 0.	0.196	0.263	0.492	0.345	0.434	0.336			
	christian	0.258	0.194	0.186	0.265	0.162	0.260	0.242	0.217	0.194
Fasttext Output	hindutva	0.189	0.161	0.154	0.061	0.285	0.247	0.168	0.173	0.161
rastiext Output	islam	0.363	0.239	0.172	0.108	0.095	0.413	0.420	0.235	0.239
	jew	0.074	0.032	0.131	0.081	0.041	0.036	0.095	0.023	0.032
	muslim	0.385	0.376	0.274	0.250	0.169	0.464	0.577	0.302	0.376
	hinduism	0.176	0.100	0.154	0.046	0.277	0.262	0.183	0.147	0.100

Table A5: Calculation of correlations between Race and Target words using word embeddings (Glove, SpaCy, Fasttext).

Race Bias	input	executive	redneck	leader	farmer	engineer	laborer	teacher	slave	musician	runner	criminal	homeless
	black	0.289	0.183	0.402	0.435	0.207	0.053	0.376	0.403	0.358	0.349	0.373	0.325
	caucasian	-0.190	0.320	0.169	0.206	-0.007	0.098	0.154	0.243	0.159	0.082	0.034	0.106
	asian	0.312	-0.012	0.373	0.276	0.143	0.012	0.249	0.239	0.155	0.369	0.277	0.203
Glove Output	african	0.385	-0.030	0.540	0.381	0.244	0.079	0.335	0.346	0.294	0.310	0.306	0.317
	white	0.371	0.084	0.434	0.438	0.166	0.043	0.308	0.311	0.219	0.303	0.354	0.248
	american	0.472	0.099	0.522	0.487	0.539	0.181	0.529	0.522	0.530	0.417	0.468	0.282
	european	0.459	-0.203	0.459	0.118	0.268	-0.076	0.209	0.230	0.181	0.394	0.318	0.114
	black	0.057	0.339	0.138	0.202	0.022	0.244	0.068	0.282	0.090	0.093	0.256	0.310
	caucasian	0.076	0.244	0.204	0.195	0.005	0.238	0.143	0.311	0.100	0.148	0.164	0.211
	asian	0.036	0.231	0.030	0.115	0.015	0.141	0.106	0.194	0.051	-0.009	0.062	0.146
SpaCy Output	african	0.195	0.120	0.211	0.270	0.185	0.258	0.167	0.271	0.219	0.015	0.150	0.199
	white	0.045	0.349	0.081	0.172	0.000	0.202	0.015	0.225	0.028	0.061	0.209	0.270
	american	0.247	0.157	0.239	0.227	0.199	0.256	0.192	0.248	0.201	0.053	0.231	0.238
	european	0.242	0.089	0.166	0.187	0.128	0.246	0.093	0.204	0.055	0.009	0.183	0.163
	black	0.316	0.417	0.328	0.353	0.276	0.223	0.302	0.345	0.359	0.392	0.394	0.349
	caucasian	0.256	0.385	0.277	0.300	0.280	0.208	0.348	0.326	0.323	0.219	0.352	0.350
	asian	0.311	0.415	0.293	0.390	0.268	0.148	0.367	0.318	0.340	0.247	0.352	0.378
Fasttext Output	african	0.278	0.349	0.298	0.380	0.149	0.261	0.314	0.345	0.351	0.264	0.279	0.490
•	white	0.286	0.404	0.286	0.309	0.295	0.214	0.279	0.321	0.345	0.394	0.382	0.365
	american	0.320	0.470	0.255	0.361	0.266	0.131	0.338	0.274	0.324	0.221	0.325	0.357
	european	0.308	0.276	0.273	0.262	0.189	0.135	0.306	0.231	0.251	0.258	0.323	0.327